



LINGUAGEM DE SINAIS E INTELIGÊNCIA ARTIFICIAL: ANÁLISE, PREDIÇÃO E CODIFICAÇÃO DE UM MODELO DETECTOR DE LIBRAS UTILIZANDO RECONHECIMENTO DE AÇÃO

CAIO CÉSAR DE JESUS CONCEIÇÃO
(caiocesa333@outlook.com)

Professor orientador: Euclério Ornellas

Curso de Engenharia da Computação

Resumo

Este trabalho investiga a integração da inteligência artificial com a linguagem de sinais, com ênfase na LIBRAS - a linguagem de sinais brasileira. O objetivo principal é desenvolver um modelo que utiliza técnicas de reconhecimento de ação para detectar e interpretar gestos LIBRAS com precisão. O método empregado combina análises de vídeo avançadas com algoritmos de aprendizado profundo de máquina para capturar e classificar movimentos específicos da Linguagem Brasileira de Sinais. Os resultados demonstram uma eficácia notável na identificação de sinais, superando modelos anteriores em termos de precisão e velocidade. Em conclusão, esta pesquisa não apenas ressalta o potencial da inteligência artificial em melhorar ferramentas de comunicação para a comunidade surda no Brasil, mas também fornece um código robusto que pode ser adaptado e utilizado em aplicações de Internet das Coisas (*IoT*).

Palavras-chave: Inteligência Artificial. Aprendizado de máquina. Programação. LIBRAS.

1. INTRODUÇÃO

Cunhado em 1956, o termo IA abrange uma complexa área da Ciência da Computação focada no desenvolvimento de máquinas capazes de performar tarefas que geralmente requerem conhecimento humano, tendo o propósito de imitar as suas habilidades cognitivas. Por ser uma área imensa e conter diversas notações, entretanto, é difícil de simplificar todo o conceito de Inteligência Artificial. McCarthy (1995) escreve “O objetivo da Inteligência Artificial é desenvolver máquinas que se comportem como se fossem inteligentes.”

No início, esta área do conhecimento era limitada pelas capacidades dos computadores da época, que não podiam armazenar comandos, apenas executá-los, pelo custo proibitivo da computação. A mudança significativa veio com a conferência de Dartmouth em 1956, organizada por John McCarthy e Marvin Minsky, onde o termo "inteligência artificial" foi cunhado e a pesquisa em IA ganhou um impulso significativo. De 1957 a 1974, a IA prosperou com melhorias em algoritmos de aprendizado de máquina e uma maior acessibilidade dos computadores. Projetos inovadores como o General Problem Solver de Newell e Simon e o ELIZA de Joseph Weizenbaum mostraram o potencial da IA em resolver problemas e

interpretar linguagem falada. No entanto, a falta de poder computacional suficiente para tarefas significativas foi um obstáculo considerável (SCIENCE IN THE NEWS, 2017).

Nos anos 90 e 2000, muitos objetivos da IA foram alcançados, como evidenciado pela vitória do programa de xadrez *Deep Blue* da IBM sobre o campeão mundial Gary Kasparov e pelo desenvolvimento de software de reconhecimento de fala. A lei de Moore, que estima que a memória e a velocidade dos computadores dobrem a cada ano, desempenhou um papel crucial na superação das limitações de armazenamento e processamento que restringiam a IA anteriormente (SCIENCE IN THE NEWS, 2017).

Neste contexto é que se insere a recente explosão dos novos modelos geradores, que estão abrindo novas fronteiras para a IA, especialmente em áreas de interface homem-máquina e acessibilidade. Uma das áreas mais promissoras é o reconhecimento e interpretação de linguagens de sinais, como a Língua Brasileira de Sinais (LIBRAS). LIBRAS é uma língua visual-espacial, com sua própria gramática e estrutura, distinta do Português falado no Brasil. Ela é a principal forma de comunicação para a comunidade surda brasileira, mas infelizmente, muitas vezes é mal compreendida ou ignorada por pessoas que não são surdas.

LIBRAS, ou Língua Brasileira de Sinais, é a riqueza linguística e cultural da comunidade surda no Brasil, não sendo meramente uma tradução manual do português, mas sim uma língua completa com sua própria gramática, sintaxe e semântica. Por muitos anos, os usuários de LIBRAS enfrentaram barreiras de comunicação com aqueles que não estavam familiarizados com essa linguagem. O obstáculo reside em sua complexidade inerente, que cria um abismo comunicativo entre os usuários de LIBRAS e aqueles que não estão familiarizados. Superar esse obstáculo exige uma abordagem altamente matizada que leva em conta as sutilezas exclusivas da LIBRAS, tornando o reconhecimento da máquina um desafio intrincado.

Integrar a aprendizado de máquina para reconhecer LIBRAS apresenta oportunidades inovadoras. Analisar um modelo que detecta e interpreta essa língua requer um profundo entendimento não só do algoritmo da máquina, mas também das sutilezas que a linguagem possui. É neste contexto de análise e integração que este trabalho se insere.

A síntese de aprendizado de máquina e LIBRAS sinaliza o advento de uma fronteira pioneira. Utilizando a linguagem Python, o foco principal desta pesquisa é formular, examinar e avaliar criticamente um modelo de aprendizado de máquina com capacidades de reconhecimento de ação. Este modelo visa detectar e interpretar gestos em LIBRAS de forma confiável e precisa, enraizando este estudo na conjunção de dois campos complexos e, como tal, exigindo uma abordagem metodológica multifacetada. Do uso de redes neurais convolucionais para reconhecimento de imagem a algoritmos de processamento de linguagem natural até a interpretação semântica, a pesquisa visa implementar um conjunto abrangente de ferramentas para alcançar uma tradução eficaz e precisa da LIBRAS para uma linguagem comum.

A confluência dessas disciplinas oferece um quadro abrangente para tratar das barreiras comunicativas enfrentadas pela comunidade surda no Brasil, fornecendo um trampolim para uma maior integração tecnológica e inclusividade.

2. DESENVOLVIMENTO


Na metade do século XX, à medida que os computadores se tornavam mais avançados, surgia a possibilidade de não apenas armazenar grandes quantidades de dados, mas também de analisar esses dados de maneira significativa. Foi nesse contexto que os primeiros algoritmos de previsão de sequência começaram a ser concebidos, visando modelar e prever padrões em séries temporais e dados ordenados.

Esses algoritmos iniciais foram revolucionários, permitindo que cientistas e pesquisadores comesçassem a explorar a previsão de eventos futuros com base em padrões históricos. Desde previsões meteorológicas até análises de tendências de mercado, a capacidade

de prever o próximo valor em uma sequência abriu novas portas para a tomada de decisão baseada em dados.

No universo do Machine Learning, especialmente na vertente do aprendizado supervisionado, a Previsão de Sequência destaca-se como uma classificação fundamental de problemas e algoritmos. Este conceito abrange o processamento e análise de sequências de dados, onde a ordem e o contexto das observações são cruciais para a extração de informações significativas e a geração de previsões precisas. Uma rede neural comumente utilizada para solucionar problemas desta natureza é chamada *Multilayer Perceptron (MLP)* ou Perceptron de Multicamadas, configurada para aceitar um número aleatório, mas fixo, de valores de entrada e de saída numa função de mapeamento, o que significa uma coisa: estaticidade. Esta falta de dinâmica representa uma das limitações deste modelo. *MLP's* são ótimos modelos para começar previsões, mas para o problema de reconhecimento de ações, precisa-se de um modelo capaz mais robusto: Redes Neurais Recorrentes.


Figura 1 – Representação de um problema de Previsão de Sequência



Fonte: (BROWLEE, 2019)

Redes Neurais Recorrentes (*RNNs*) são um tipo de arquitetura de rede neural artificial projetada para reconhecer padrões em sequências de dados, como séries temporais, linguagem falada, ou, no caso de LIBRAS, talvez sequências de gestos. Ao contrário das redes neurais convolucionais (*CNNs*) e redes neurais *feedforward*, que têm conexões apenas na direção para a frente, *RNNs* têm conexões recorrentes, ou seja, loops dentro da rede.

Figura 2 – Ilustração da diferença entre uma rede neural feedfoward e uma *RNN*



Fonte: <https://www.analyticsvidhya.com/blog/2020/02/cnn-vs-rnn-vs-mlp-analyzing-3-types-of-neural-networks-in-deep-learning/>

Este tipo de rede é particularmente útil para tarefas onde o contexto ou a ordem dos dados é importante, já que a arquitetura permite que informações sejam carregadas de um passo do processo para o próximo. Isso torna as *RNNs* adequadas para tarefas como tradução de linguagem, análise de sentimento, e reconhecimento de fala.

O modelo utilizado, *Long Short-Term Memory*, é um tipo de *RNN* capaz de aprender a função de mapeamento de um problema, ao invés de mapear apenas as entradas e saídas. A cada recorrência, a saída é atualizada de acordo com o estado de cada neurônio anterior. Neste caso, o problema do desaparecimento do gradiente da função de mapeamento é resolvido, permitindo computar valores sequenciais utilizando dependências de longo prazo que compoem a memória do modelo.

Além do entendimento teórico acerca da construção do modelo (RUSSELL S, NORVIG P, DAVIS E, 2005), outros trabalhos específicos foram estudados na produção deste elemento acadêmico. Um estudo significativo demonstrou a eficácia do *LSTM* no reconhecimento do alfabeto da Língua de Sinais Americana (*ASL*), alcançando uma precisão de 99% (B SUNDAR, T BAGYAMMAL, 2022). Esse sucesso sugere a adaptabilidade do *LSTM* para interpretar gestos manuais estáticos e específicos, um aspecto crucial para a identificação de sinais em LIBRAS. Da mesma forma, a pesquisa sobre o uso de MediaPipe Holistic com *LSTM* ressalta a importância de combinar tecnologias de detecção de movimento com modelos de aprendizado de máquina, melhorando assim a precisão e eficácia do reconhecimento de sinais (A. MITTAL, P. KUMAR, P. P. ROY, R. BALASUBRAMANIAN AND B. B. CHAUDHURI, 2019).

Ao prosseguir com os estudos, desta vez sobre o modelo *LSTM*, foi proposto uma modificação para reconhecer sequências contínuas de gestos, destacando-se pela sua capacidade de processar sinais contínuos dividindo-os em subunidades (MALI, P., SHAKYA, A., PANDAY, S.P., 2023). Este método é particularmente relevante para a LIBRAS, onde os gestos frequentemente fluem de um para o outro em frases complexas.

Adicionalmente, a combinação de *LSTM* com redes neurais convolucionais (*CNN*) foi investigada, focando na *ISL* (*Indian Sign Language*). Esta pesquisa ressalta a eficácia de combinar diferentes arquiteturas de rede neural para criar um sistema mais robusto e adaptabilidade do processo de codificação com o intuito de fornecer uma fácil alternância na localização das linguagens de sinais (APARNA, C., GEETHA, M. 2020).

Esses estudos coletivamente demonstram o potencial dos modelos *LSTM* no contexto de reconhecimento de linguagem de sinais. A aplicação desses conceitos ao contexto da LIBRAS pode levar ao desenvolvimento de um sistema de reconhecimento de gestos mais eficiente e abrangente, capaz de entender tanto sinais isolados quanto sequências complexas de gestos e expressões, elementos essenciais na comunicação através da linguagem de sinais.

Em termos de precisão dos resultados de teste, conceito de *multilabel_confusion_matrix* da biblioteca *scikit-learn* à discussão enriquece a compreensão da avaliação de modelos em classificações multirrótulos. A matriz de confusão é calculada classe por classe para avaliar a precisão de um modelo de classificação, fornecendo matrizes de confusão separadas para cada classe ou amostra. Em contextos como o reconhecimento de LIBRAS, onde múltiplos gestos podem ser representados em uma única sequência, essa abordagem facilita uma análise detalhada da performance do modelo em cada gesto ou ação específica. Juntamente com este conceito, o *accuracy_score*, da mesma biblioteca, mede a precisão de classificação. Em classificação multirrótulos, essa função calcula a precisão do subconjunto, onde o conjunto de rótulos previstos para uma amostra deve corresponder exatamente ao conjunto de rótulos reais. (SCIKIT-LEARN: MACHINE LEARNING IN PYTHON, PEDREGOSA ET AL., JMLR 12, PP. 2825-2830, 2011.)


Em contrapartida, a precisão do treinamento foi obtida pela *categorical_crossentropy* (CHOLLET, François et al. Keras. 2015. Disponível em: <https://keras.io>. Acesso em: 2023),

uma métrica importante para modelos de classificação multiclasse, como os usados no reconhecimento de ação. Ela combina uma ativação *Softmax* com uma perda de entropia cruzada, fornecendo um método eficaz para treinar redes neurais para prever a probabilidade de várias classes. Paralelamente, a *categorical_accuracy* oferece uma medida direta da eficácia de um modelo em classificar entradas em suas respectivas classes, sendo crucial para monitorar e otimizar o desempenho do modelo em seu treino.

3. METODOLOGIA

Por se tratar do ponto focal, e dada a importância central do reconhecimento preciso e eficiente de gestos em LIBRAS, optou-se pelo uso do *MediaPipe Holistic* na codificação do modelo. Este framework oferece uma solução abrangente para o reconhecimento de ações em tempo real, integrando detecção de mão, pose e rosto. Sua capacidade de processar imagens e vídeos de forma rápida e eficiente o torna ideal para capturar a dinâmica complexa dos gestos de LIBRAS.

Figura 3 – Representação dos *keypoints* renderizados em tempo real na webcam



Fonte: https://www.researchgate.net/figure/Two-handed-recognition-scheme-using-MediaPipe-Holistic-API-hand-landmarks_fig1_369770026

O MediaPipe Holistic fornece *keypoints* detalhados para mãos, rosto e postura do corpo. No modelo, cada frame de vídeo é analisado para extrair esses *keypoints*, que são então utilizados como dados de entrada para a rede neural. Esta abordagem permite que o modelo capture não apenas a posição e o movimento das mãos, mas também expressões faciais e posturas corporais, que são elementos cruciais na LIBRAS.

O protótipo deste modelo codificado utiliza de três avaliações classificativas (labels) em libras gravadas frame à frame. Suas traduções são “Oi”, “Obrigado” e “Eu te amo”.

Para cada um desses gestos, o modelo é treinado com vídeos gravados frame a frame, 30 frames por vídeo, onde cada frame é analisado pelo *MediaPipe Holistic* para extrair

keypoints. Esses *keypoints*, que representam as nuances de movimento e expressão de cada gesto, são fundamentais para ensinar o modelo a distinguir com precisão entre as diferentes avaliações classificativas.

O treinamento eficaz do modelo requer um conjunto de dados anotados, onde cada gesto de LIBRAS é claramente identificado e etiquetado. Isso envolve a anotação manual de vídeos, garantindo que cada gesto seja corretamente associado aos seus respectivos *keypoints*. Essa anotação detalhada permite que o modelo aprenda as características específicas de cada gesto de LIBRAS, formando a base para previsões precisas.

Com o intuito de se treinar o modelo, foram gravados cerca de 150 vídeos, 50 vídeos por ação e armazenados em subpastas do projeto. Cada uma das subpastas contém 30 frames capturados utilizando a biblioteca *opencv* com 1662 pontos de referências (*keypoints*) em cada um deles.

O resultado deste treinamento foi um modelo capaz de, não só renderizar e capturar rapidamente as ações, mas também renderizá-las na tela em tempo real, calculando a probabilidade da próxima palavra de maneira sucinta, ainda que contida.

Figura 4 – Representação do funcionamento do modelo com a ação “Obrigado” sendo renderizada e prevista



Fonte: Caio César, 2023

Devido à necessidade de se avaliar o desempenho do modelo, a avaliação da precisão de medida será feita utilizando uma matriz de confusão. O método da matriz de confusão, ou matriz de erro, importada através do *sklearn.metrics*, é uma tabela resumida usada para avaliar o desempenho de um modelo de classificação. Ela tabula o número de previsões corretas e incorretas, discriminadas por classe. Os principais termos associados são:

- Verdadeiro Positivo (TP): O modelo prevê corretamente a classe positiva
- Verdadeiro Negativo (TN): O modelo prevê corretamente a classe negativa.
- Falso Positivo (FP): O modelo prevê incorretamente a classe positiva (também chamado de erro tipo 1).

- Falso Negativo (FN): O modelo prevê incorretamente a classe negativa (também chamado de erro tipo 2)

Figura 5 – Representação de uma matriz de confusão 2x2

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Fonte: Diego Nogare Inteligência Artificial, Linguagem R, Machine Learning, Python 2020

A matriz de confusão, também conhecida como matriz de erro, é uma tabela resumida usada para avaliar o desempenho de um modelo de classificação. Ela tabula o número de previsões corretas e incorretas, discriminadas por classe. Os principais termos associados são:

- Verdadeiro Positivo (TP): O modelo prevê corretamente a classe positiva
- Verdadeiro Negativo (TN): O modelo prevê corretamente a classe negativa.
- Falso Positivo (FP): O modelo prevê incorretamente a classe positiva (também chamado de erro tipo 1).
- Falso Negativo (FN): O modelo prevê incorretamente a classe negativa (também chamado de erro tipo 2) (LEVER, J., KRZYWINSKI, M. & ALTMAN, N., 2016)

No modelo, converte-se as previsões das suas representações codificadas para as classificações necessárias. Dessa forma, é possível transformar matrizem em inteiros e.g [1,0,0], [0,1,0], [0,0,1] em 0, 1 e 2, que neste caso representam “Oi”, “Obrigado” e “Eu te amo” respectivamente.

Na execução deste teste, é ideal que os valores recebidos pelo *array* estejam deslocados para a diagonal principal da matriz, pois, se tratando desta matriz de confusão, com formato 2x2, a diagonal principal indica os valores Verdadeiros (positivos e negativos).


Para a precisão do treinamento do modelo, ao contrário dos testes utiliza-se, como função de custo/perda e função de precisão do treinamento do modelo, *categorical_crossentropy* e *categorical_accuracy* respectivamente. A *categorical_crossentropy*, também conhecida como Softmax Loss, é uma combinação de ativação Softmax com uma perda de entropia cruzada. Essencialmente, ao treinar uma CNN para classificação multiclasse, essa função de perda ajudará a modelar a saída para fornecer uma probabilidade distribuída pelas classes C para cada imagem. No caso específico e comum de classificação multiclasse, as etiquetas (labels) são codificadas de forma "one-hot", ou seja, apenas a classe positiva mantém seu termo na perda. A perda de entropia cruzada categórica é então definida como $CE = -\log \frac{e^{sp}}{\sum_j e^{s_j}}$ onde sp é a pontuação da CNN para a classe positiva.

Esse método é particularmente útil em contextos como o reconhecimento de LIBRAS, onde diversas classes (gestos) precisam ser diferenciadas. A função ajuda o modelo a entender qual classe é mais provável que corresponda à entrada dada, penalizando previsões erradas de forma mais eficaz.

Já a *categorical_accuracy*, por outro lado, calcula a porcentagem de valores previstos ($yPred$) que correspondem aos valores reais ($yPred = yTrue$) para rótulos one-hot. No modelo em questão, '*K.argmax*' foi utilizado para comparar os índices das previsões. Em cada instância de previsão, o modelo gera um vetor de probabilidades ou *logits* ($yPred$), onde cada elemento representa a probabilidade de a entrada pertencer a uma determinada classe. O método '*K.argmax*' identifica o índice do valor máximo nesse vetor, que representa a classe prevista pelo modelo. Em termos práticos, este método é utilizado para comparar o índice do valor verdadeiro máximo com o índice do valor previsto máximo. Isso se traduz em medir “com que frequência as previsões têm o máximo no mesmo local que os valores verdadeiros”. Para calcular a acurácia categórica, divide-se o número de registros previstos corretamente pelo número total de registros. Como a acurácia categórica procura pelo índice do valor máximo, $yPred$ pode ser uma função *logit* - $Logit(p) = \log(p / (1 - p))$ (uma função de ligação que mapeia probabilidades variando entre 0 e 1 para números reais em toda a linha numérica, que podem então ser usados para expressar relações lineares) ou uma probabilidade das previsões.

O processo do código, em resultado, pode ser demonstrado pelo seguinte fluxograma:

Figura 6 - Fluxograma de demonstração do processo lógico do código utilizado para se obter o modelo.



No contexto do reconhecimento de LIBRAS, a matriz de confusão e as métricas citadas serão utilizadas para avaliar como o modelo classifica diferentes gestos e ações. A análise detalhada fornecida pelos valores relacionados ajudará a identificar pontos fortes e fracos do modelo, orientando melhorias e ajustes para aumentar a precisão e a eficácia do sistema de reconhecimento de gestos.

4. RESULTADOS E DISCUSSÕES

Para o treinamento do modelo, utilizou-se o MediaPipe Holistic para obter uma variável chamada *results*, que passará pelo método *extract_keypoints*:

Figura 7 –, função de extração dos pontos de referências das mãos, face e pose.

```
def extract_keypoints(results):
    pose = np.array([[res.x, res.y, res.z, res.visibility]
                     for res in results.pose_landmarks.landmark]).flatten()
    if results.pose_landmarks else np.zeros(33*4)
    face = np.array([[res.x, res.y, res.z]
                     for res in results.face_landmarks.landmark]).flatten()
    if results.face_landmarks else np.zeros(468*3)
    lh = np.array([[res.x, res.y, res.z]
                   for res in results.left_hand_landmarks.landmark]).flatten()
    if results.left_hand_landmarks else np.zeros(21*3)
    rh = np.array([[res.x, res.y, res.z]
                   for res in results.right_hand_landmarks.landmark]).flatten()
    if results.right_hand_landmarks else np.zeros(21*3)
    return np.concatenate([pose, face, lh, rh])
```

Fonte: Caio César, 2023

O método em questão nos retornará um *array* de *shape* = (1662,) contendo os pontos de referência que utilizar-se-á para traduzir o movimento em números, com o intuito de compará-los aos dados de treinamento. Em suma, para gravação de cada uma das ações (palavras) retorna-se 30 vídeos, cada um contendo 30 frames. Sendo assim, para o primeiro teste de 3 ações (“Oi”, “Obrigado” e “Eu te amo”.) foram necessários 90 vídeos. Esta é a primeira dificuldade do método utilizado, advinda da falta de datasets predefinidos com *keypoints* em Libras.

A medida dos parâmetros de treinamento do modelo, neste sentido, foi ótima. A função de perda retornou um número extremamente pequeno, enquanto a precisão do treinamento foi de 100%. Pelo cálculo da matriz de confusão dadas pelo material de teste obtido no treinamento do modelo, é possível obter uma *accuracy_score* (função que calcula a precisão de um subconjunto onde o conjunto de rótulos específicos devem corresponder exatamente às classificações previstas pelo Positivo Verdadeiro) retornando 1.0. Isso significa que o modelo foi capaz de aprender bem em um dataset pequeno de dados de entrada (90 vídeos e 1662 keypoints extraídos). Além de um bom *accuracy_score*, nossa matriz de confusão retornou valores na diagonal principal, evidenciando um bom parâmetro de funcionamento do modelo.

Figura 8 – representação da matriz de confusão calculada utilizando os dados de teste e três ações

```
array([[1, 0],
       [0, 4]],

       [[4, 0],
       [0, 1]]], dtype=int64)
```

Fonte: Caio César, 2023

Como resultado final, o protótipo foi capaz de “traduzir” de maneira adequada as três ações sem delay’s, devida a taxa de previsão.

Com um conjunto de dados um pouco maior (ao acrescentar-se-á as palavras “Desculpa” e “Inteligente/Inteligencia”, aumentando a quantidade de vídeos para 150) o conjunto inicial de *epochs* teve valores altos de perda, eu foi suavizado ao longo das iterações.

Figura 9 – Representação do treinamento do modelo

```
Epoch 8/2000
5/5 [=====] - 0s 92ms/step - loss: 1.6755 - categorical_accuracy: 0.2993
Epoch 9/2000
5/5 [=====] - 0s 96ms/step - loss: 2.0414 - categorical_accuracy: 0.2041
Epoch 10/2000
5/5 [=====] - 0s 98ms/step - loss: 1.8126 - categorical_accuracy: 0.1633
Epoch 11/2000
5/5 [=====] - 1s 109ms/step - loss: 1.6624 - categorical_accuracy: 0.1973
Epoch 12/2000
5/5 [=====] - 1s 99ms/step - loss: 1.6536 - categorical_accuracy: 0.1633
Epoch 13/2000
5/5 [=====] - 0s 97ms/step - loss: 1.6431 - categorical_accuracy: 0.1769
Epoch 14/2000
5/5 [=====] - 0s 100ms/step - loss: 1.6206 - categorical_accuracy: 0.1973
Epoch 15/2000
```

Fonte: Caio César, 2023

Neste contexto, as funções de custo e de precisão de treinamento do modelo receberam o valor de 0.2930 e 0.9062, respectivamente, na *epoch* 243, valores estes que podem ser melhorados. A matriz de confusão e a *accuracy_score* se mantiveram com ótimos valores:

Figura 10 – representação da matriz de confusão calculada utilizando os dados de treinamento e cinco ações

```
[66]: multilabel_confusion_matrix(ytrue, yhat)
```

```
[66]: array([[5, 0],  
          [0, 3]],  
  
        [[5, 0],  
          [0, 3]],  
  
        [[7, 0],  
          [0, 1]],  
  
        [[7, 0],  
          [0, 1]]], dtype=int64)
```

```
[67]: accuracy_score(ytrue, yhat)
```

```
[67]: 1.0
```

Fonte: Caio César, 2023

Desta forma, o modelo treinado com 5 ações também foi capaz de fazer ótimas previsões e de traduzir eficientemente as palavras na tela, com um delay de alguns segundos.

Inicialmente, o modelo demonstrou uma capacidade notável de "traduzir" as três ações ("Oi", "Obrigado" e "Eu te amo") sem atrasos significativos. Isso é evidenciado pelo alto valor de `accuracy_score` de 1.0 e pelos resultados positivos na matriz de confusão, onde os valores predominam na diagonal principal. Estes indicadores sugerem que o modelo foi eficiente em aprender e classificar corretamente os gestos com base no conjunto inicial de 90 vídeos.

Ademais, a expansão do conjunto de dados para incluir as palavras "Desculpa" e "Inteligente/Inteligencia" aumentou a complexidade do modelo, elevando o número total de vídeos para 250. Uma preocupação emergente é o potencial de overfitting, especialmente ao considerar um número elevado de epochs no treinamento. Embora a função de perda e a precisão do treinamento tenham mostrado valores razoáveis (0.2930 e 0.9062, respectivamente, na epoch 243), ainda existe espaço para otimização. E apesar dos desafios adicionais, o modelo ampliado continuou a mostrar bons resultados, tanto na matriz de confusão quanto na `accuracy_score`. Isso indica que o modelo, mesmo com o aumento do volume de dados, conseguiu manter uma alta taxa de previsão e uma boa capacidade de classificação das ações.

Ainda se tratando do modelo expandido Um aspecto notável é a presença de um delay de alguns segundos na "tradução" das ações. Este aspecto aponta para a necessidade de otimizações adicionais, visando não apenas manter a precisão, mas também melhorar a eficiência temporal do modelo, especialmente importante em aplicações práticas de reconhecimento de gestos em tempo real.

5 CONCLUSÕES

O desenvolvimento deste projeto, focado na análise, predição e codificação de um modelo de detecção de LIBRAS (Língua Brasileira de Sinais) utilizando reconhecimento de ação, representou um avanço significativo na interseção entre inteligência artificial e acessibilidade. Através de uma abordagem inovadora que integrou a tecnologia MediaPipe

Holistic para extração de keypoints e a aplicação de redes neurais *LSTM*, foi possível traduzir gestos e expressões de LIBRAS em tempo real. Este feito foi alcançado não apenas com alta precisão, como demonstrado pelos resultados obtidos na matriz de confusão e na *accuracy_score*, mas também com uma eficiência notável, considerando as limitações inerentes a conjuntos de dados pequenos e os desafios de overfitting.

O trabalho realizado contribui bem para a pesquisa em inteligência artificial aplicada à linguagem de sinais no âmbito brasileiro, um campo ainda emergente, mas de crucial importância para a inclusão de pessoas surdas no país. A capacidade do modelo de "traduzir" ações de LIBRAS com precisão e em tempo real abre caminhos para novas aplicações práticas, como em dispositivos de assistência e plataformas de comunicação acessíveis.

Embora o projeto tenha alcançado resultados promissores, ele também destacou várias áreas para melhoria e pesquisa futura. O desafio do overfitting em conjuntos de dados maiores, a necessidade de otimizar o tempo de resposta do modelo e a expansão controlada do conjunto de dados para incluir uma gama mais ampla de gestos e expressões de LIBRAS são algumas das áreas que oferecem oportunidades para trabalhos futuros. Além disso, a exploração de técnicas adicionais, como ensembles de modelos e ajustes finos em arquiteturas de rede, poderia melhorar ainda mais a eficácia do modelo.

Em suma, este trabalho representa um passo importante na aplicação de tecnologias de inteligência artificial para a tradução de linguagem de sinais, com potencial para impactar positivamente a vida de muitas pessoas. Ao continuar explorando e aprimorando essas tecnologias, pode-se esperar avanços significativos na comunicação e na acessibilidade para a comunidade surda.

REFERÊNCIAS BIBLIOGRÁFICAS

APARNA, C.; GEETHA, M. CNN and Stacked *LSTM* Model for Indian Sign Language Recognition. In: THAMPI, S. M.; TRAJKOVIC, L.; LI, K.-C.; DAS, S.; WOZNIAK, M.; BERRETTI, S. (Ed.). *Machine Learning and Metaheuristics Algorithms, and Applications*. Singapura: Springer, 2020. p. 126-134.

MALI, P.; SHAKYA, A.; PANDAY, S. P. Sign Language Recognition Using Long Short-Term Memory Deep Learning Model. In: SHAKYA, S.; TAVARES, J. M. R. S.; FERNÁNDEZ-CABALLERO, A.; PAPAKOSTAS, G. (Ed.). *Fourth International Conference on Image Processing and Capsule Networks*. Singapura: Springer Nature, 2023. p. 697-709.

MITTAL, A.; KUMAR, P.; ROY, P. P.; BALASUBRAMANIAN, R.; CHAUDHURI, B. B. A Modified *LSTM* Model for Continuous Sign Language Recognition Using Leap Motion. *IEEE Sensors Journal*, v. 19, n. 16, p. 7056–7063, 2019. Disponível em: <https://doi.org/10.1109/JSEN.2019.2909837>. Acesso em: 2023.

LEVER, J.; KRZYWINSKI, M.; ALTMAN, N. Classification evaluation. *Nature Methods*, v. 13, n. 8, p. 603–604, 2016. Disponível em: <https://doi.org/10.1038/nmeth.3945>. Acesso em: 2023.

SUNDAR, B.; BAGYAMMAL, T. American Sign Language Recognition for Alphabets Using MediaPipe and *LSTM*. *Procedia Computer Science*, v. 215, p. 642–651, 2022. Disponível em: <https://doi.org/10.1016/j.procs.2022.12.066>. Acesso em: 2023.

LUGARESI, C.; TANG, J.; NASH, H. et al. MediaPipe: A Framework for Building Perception Pipelines. 2019. Disponível em: <http://arxiv.org/abs/1906.08172>. Acesso em: 2023.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14724**: informação e documentação: trabalhos acadêmicos: apresentação. Rio de Janeiro: ABNT, 2011.

LOPES, R. R. Aprendizado de Máquina Baseado em Tensores e suas Aplicações para Floresta de Caminhos Ótimos.

BROWNLEE, Jason. Long Short-Term Memory Networks With Python. Google Books. Disponível em: <URL do livro no Google Books>. Acesso em: [data de acesso].

RUSSELL, S. J.; NORVIG, P.; DAVIS, E. Artificial intelligence: a modern approach.

RENOTTE, Nicholas. (2020). [Vídeo]. Disponível em: https://www.youtube.com/watch?v=doDUihpj6ro&ab_channel=NicholasRenotte. Acesso em: 2023

WHEN to use "categorical accuracy vs sparse categorical accuracy" in Keras? [S.l.: s.n.], [s.d.]. Disponível em: https://androidkt.com/when-use-categorical_accuracy-sparse_categorical_accuracy-in-keras/#:~:text=Categorical%20Accuracy%20calculates%20the%20percentage,hot%20labels. Acesso em: 2023.

UNDERSTANDING Categorical Cross-Entropy Loss, Binary Cross-Entropy Loss, Softmax Loss, Logistic Loss, Focal Loss and all those confusing names. [S.l.: s.n.], [s.d.]. Disponível em: https://gombru.github.io/2018/05/23/cross_entropy_loss/. Acesso em: 2023.

DEEPAI. Logit. Disponível em: <https://deepai.org/machine-learning-glossary-and-terms/logit>. Acesso em: 2023.

SCIKIT-LEARN: MACHINE LEARNING IN PYTHON, PEDREGOSA ET AL., JMLR 12, PP. 2825-2830, 2011.

BANERJEE, Kunal; PRASAD, Vishak C.; GUPTA, Rishi Raj; VYAS, Karthik; H, Anushree; MISHRA, Biswajit. Exploring Alternatives to Softmax Function. 2020. Disponível em: <https://doi.org/10.48550/arXiv.2011.11538>. Acesso em: 2023

CHOLLET, François et al. Keras. 2015. Disponível em: <https://keras.io>. Acesso em: 2023

SCIENCE IN THE NEWS. The History of Artificial Intelligence. Disponível em: <https://sitn.hms.harvard.edu/flash/2017/history-artificial-intelligence/>. Acesso em: 2023

RESEARCH GATE. Application of Wearable Gloves for Assisted Learning of Sign Language Using Artificial Neural Networks. Esquema de reconhecimento de duas mãos usando API de pontos de referência da mão MediaPipe Holistic. Disponível em: <https://www.researchgate.net/figure/Two-handed-recognition-scheme-using-MediaPipe->

Holistic-API-hand-landmarks_fig1_369770026. Acesso em: 2023.